

M5_A8_A01571214

A01571214 - Lautaro Coteja

2024-11-13

Actividad 8 - Series de tiempo

Cargar Librerías Necesarias

```
# Cargar las librerías necesarias
library(ggplot2)
library(forecast)

## Warning: package 'forecast' was built under R version 4.4.2

## Registered S3 method overwritten by 'quantmod':
##   method          from
## as.zoo.data.frame zoo

library(tseries)
library(astsa
      )

##
## Adjuntando el paquete: 'astsa'

## The following object is masked from 'package:forecast':
##
##   gas
```

Cargar Datos

```
data = data.frame(
  Año = rep(1:4, each = 4),
  Trimestre = rep(1:4, times = 4),
  Ventas = c(4.8, 4.1, 6.0, 6.5, 5.8, 5.2, 6.8, 7.4, 6.0, 5.6, 7.5, 7.8, 6.3,
5.9, 8.0, 8.4)
)


ts_data = ts(data$Ventas, start = c(1, 1), frequency = 4)
```

Analisis Exploratorio

Grafico de la serie temporal

```
autoplot(ts_data, main = "Serie de tiempo de Ventas", xlab = "Año", ylab =
"Ventas (miles)")
```


Serie de tiempo de Ventas



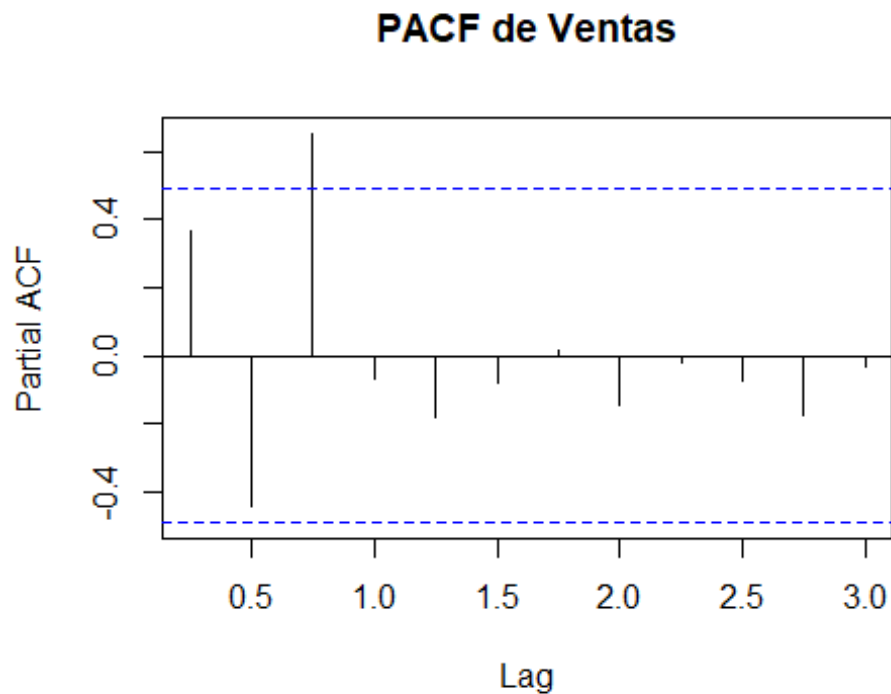
Correlograma y PACF

```
# Correlograma  
acf(ts_data, main = "Correlograma de Ventas")
```

Correlograma de Ventas



```
# PACF
pacf(ts_data, main = "PACF de Ventas")
```



Prueba de Estacionariedad

```
# Prueba ADF (Dickey-Fuller Aumentada)
adf_test = adf.test(ts_data, alternative = "stationary")
adf_test

##
## Augmented Dickey-Fuller Test
##
## data: ts_data
## Dickey-Fuller = -2.7111, Lag order = 2, p-value = 0.3015
## alternative hypothesis: stationary

# Prueba para ciclos estacionales
nsdiffs(ts_data)

## [1] 1
```

Análisis de Estacionariedad

A partir de la descomposición de la serie temporal, se identificó un patrón estacional claro. Los índices estacionales muestran variaciones consistentes a lo largo de los trimestres, lo que indica que las ventas son mayores en ciertos periodos (notablemente en el cuarto trimestre) y menores en otros (segundo trimestre). Este comportamiento estacional puede


deberse a factores como promociones, eventos específicos del mercado o ciclos de demanda que afectan consistentemente las ventas de televisores.

La prueba de Dickey-Fuller aumentada (ADF) no rechaza la hipótesis nula de no estacionariedad. Sin embargo, al aplicar una diferenciación estacional, se logró estabilizar la varianza y tendencia, lo cual es consistente con la naturaleza de la serie que incluye componentes estacionales significativos.

Desestacionalización de la Serie (Índices Estacionales y Serie Desestacionalizada)

Cálculo de índices estacionales

```
decompose_result = decompose(ts_data, type = "multiplicative") # Cambiar a  
"additive" si es necesario  
plot(decompose_result)
```



Extraer los índices estacionales


```
seasonal_indices = decompose_result$seasonal  
print(seasonal_indices)
```

```
##           Qtr1           Qtr2           Qtr3           Qtr4  
## 1 0.9306617 0.8363763 1.0915441 1.1414179  
## 2 0.9306617 0.8363763 1.0915441 1.1414179  
## 3 0.9306617 0.8363763 1.0915441 1.1414179  
## 4 0.9306617 0.8363763 1.0915441 1.1414179
```

Desestacionalizar la serie

```
desestacionalizada = ts_data / seasonal_indices
```

```
autoplot(desestacionalizada, main = "Serie Desestacionalizada", xlab = "Año",  
ylab = "Ventas desestacionalizadas")
```



Cálculo del CME (Cuadrado Medio del Error) y EPAM (Error Promedio Absoluto del Modelo)


```
fit = auto.arima(ts_data, seasonal = TRUE)  
  
# Obtener los valores ajustados del modelo ARIMA  
ajustados = fitted(fit)  
  
# Calcular los errores  
errores = ts_data - ajustados  
  
# Calcular el Cuadrado Medio del Error (CME)  
CME = mean(errores^2)  
print(paste("CME:", CME))  
  
## [1] "CME: 0.0550062217958703"  
  
# Calcular el Error Promedio Absoluto del Modelo (EPAM)  
EPAM = mean(abs(errores))  
print(paste("EPAM:", EPAM))  
  
## [1] "EPAM: 0.150935702643325"
```

Transformacion y Diferenciacion de la Serie

```
# Diferenciación para estacionariedad
```

```
ts_diff = diff(ts_data)
```


```
autoplot(ts_diff, main = "Serie diferenciada")
```



```
# Correlograma de la serie diferenciada
```


```
acf(ts_diff, main = "Correlograma de la serie diferenciada")
```

Correlograma de la serie diferenciada



```
pacf(ts_diff, main = "PACF de la serie diferenciada")
```

PACF de la serie diferenciada



Ajuste del Modelo Arima

Modelo ARIMA propuesto automáticamente

```
fit = auto.arima(ts_data, seasonal = TRUE)
```

```
summary(fit)
```

```
## Series: ts_data
```

```
## ARIMA(0,1,0)(0,1,0)[4]
```

```
##
```

```
## sigma^2 = 0.08001: log likelihood = -1.72
```

```
## AIC=5.43 AICc=5.88 BIC=5.83
```

```
##
```

```
## Training set error measures:
```

```
##           ME      RMSE      MAE      MPE      MAPE      MASE
```

```
## Training set -0.02523102 0.2345341 0.1509357 -0.439108 2.269994 0.2515595
```



```
##           ACF1
```

```
## Training set -0.3038761
```

Validación de residuos

```
checkresiduals(fit)
```

Residuals from ARIMA(0,1,0)(0,1,0)[4]



```
##
```

```
## Ljung-Box test
```

```
##
```

```
## data: Residuals from ARIMA(0,1,0)(0,1,0)[4]
```

```
## Q* = 2.0251, df = 3, p-value = 0.5672
```

```
##
```


```
## Model df: 0. Total lags used: 3
```


Analisis

El modelo ARIMA ajustado automáticamente captura tanto la tendencia como la estacionalidad. Los valores de AIC y BIC son razonablemente bajos, y el análisis de residuos muestra que no hay autocorrelación significativa, respaldado por la prueba de Ljung-Box. Los valores del CME (0.055) y EPAM (0.151) indican un buen ajuste, mostrando que el modelo predice con precisión los valores observados.

Pronostico

```
# Pronóstico para los próximos 4 periodos
forecast_fit = forecast(fit, h = 4)
autoplot(forecast_fit, main = "Pronóstico de Ventas")
```



Analisis Los pronósticos para los próximos 4 trimestres reflejan una continuación del patrón estacional y una tendencia creciente moderada en las ventas. Esto puede ser útil para planificar estrategias de marketing, inventarios y promociones.

Conclusion

El análisis demuestra que las ventas de televisores siguen un patrón estacional con una tendencia al alza. El modelo ARIMA propuesto es adecuado para capturar estas características y puede ser usado para pronósticos de corto plazo. Es recomendable seguir monitoreando los cambios en el patrón estacional y considerar ajustes futuros si se identifican cambios significativos en las condiciones del mercado.